

Fenotipagem Laboratorial Não Supervisionada Revela Padrões Clínicos Distintos Independentes do Contexto Assistencial

data-driven clinical phenotyping (diagnosis-agnostic)

latent biological phenotyping in undifferentiated emergency patients

perfil de atendimento, média, desvio padrão, por sexo...idade....

Introdução: A interpretação de exames laboratoriais na prática clínica é tradicionalmente orientada por hipóteses diagnósticas prévias e pelo contexto assistencial. Entretanto, a heterogeneidade dos pacientes, especialmente em cenários de urgência e emergência, sugere que padrões biológicos subjacentes podem não ser plenamente capturados por abordagens convencionais baseadas em biomarcadores isolados. **Objetivo:** Identificar fenótipos laboratoriais distintos a partir de dados clínicos reais utilizando técnicas de aprendizado de máquina não supervisionado, e avaliar sua relação com o contexto assistencial. **Métodos:** Foi conduzido um estudo retrospectivo utilizando dados laboratoriais de atendimentos clínicos entre 2022 e 2024. Foram incluídos marcadores inflamatórios, renais, hepáticos e hematológicos, agregados nas primeiras 24 horas de atendimento. Após padronização das variáveis e tratamento de dados faltantes, foi aplicado o algoritmo K-means para identificação de agrupamentos. A projeção bidimensional foi realizada com UMAP para visualização. A associação entre fenótipos e contexto assistencial foi avaliada por teste do qui-quadrado e tamanho de efeito (V de Cramér). **Resultados:** Um total de 26.414 atendimentos foi incluído na análise. Três fenótipos laboratoriais foram identificados: (1) fenótipo inflamatório-renal, caracterizado por elevação de proteína C reativa, creatinina e ureia, associado a maior idade; (2) fenótipo hepático, com elevação de transaminases e redução relativa de leucócitos e plaquetas; e (3) fenótipo basal, com parâmetros laboratoriais próximos da normalidade. A distribuição dos fenótipos apresentou associação estatisticamente significativa com o contexto assistencial ($p < 0,001$), porém com tamanho de efeito pequeno ($V \text{ de Cramér} = 0,052$), indicando baixa dependência entre as variáveis. **Conclusão:** Dados laboratoriais multimarcadores permitem a identificação de fenótipos clínicos distintos de forma não supervisionada. Esses padrões não são fortemente determinados pelo contexto assistencial, sugerindo que a fenotipagem baseada em dados pode representar uma abordagem complementar para estratificação de pacientes na prática clínica.

palavras-chaves:

abstract

keywords:

Introdução

Os serviços de urgência e emergência representam um dos cenários mais complexos da prática clínica, caracterizados por elevada heterogeneidade de pacientes, ampla variabilidade fisiopatológica e necessidade de tomada de decisão rápida. Pacientes atendidos nesses ambientes frequentemente apresentam manifestações clínicas inespecíficas, múltiplas comorbidades e diferentes níveis de gravidade, tornando a interpretação integrada de informações clínicas e laboratoriais um desafio importante na prática assistencial¹.

Na rotina dos serviços de emergência, exames laboratoriais são amplamente utilizados como ferramentas objetivas para avaliação inicial, estratificação de risco e monitoramento clínico. Marcadores inflamatórios, hematológicos, renais e hepáticos podem refletir diferentes estados fisiopatológicos subjacentes, incluindo inflamação sistêmica, disfunção orgânica e alterações metabólicas. Entretanto, a interpretação desses exames geralmente ocorre de forma isolada ou orientada por hipóteses diagnósticas específicas, podendo limitar a identificação de padrões biológicos mais complexos presentes em populações heterogêneas².

Nos últimos anos, avanços em ciência de dados e aprendizado de máquina têm possibilitado a análise integrada de grandes volumes de dados clínicos, permitindo a identificação de subgrupos de pacientes por meio de técnicas não supervisionadas. Métodos de clusterização têm sido amplamente aplicados em doenças complexas, como sepse, síndrome do desconforto respiratório agudo e COVID-19, revelando fenótipos clínicos latentes associados a diferentes perfis inflamatórios, prognósticos e respostas terapêuticas. Esses estudos demonstram que pacientes classificados sob um mesmo diagnóstico podem apresentar substancial heterogeneidade biológica, evidenciando limitações de abordagens tradicionais baseadas exclusivamente em categorias diagnósticas³.

Do ponto de vista aplicado, a identificação de fenótipos laboratoriais em populações heterogêneas de emergência pode contribuir para uma compreensão mais abrangente dos perfis clínico-biológicos presentes nesses serviços. Essa abordagem não tem como objetivo substituir a avaliação médica ou estabelecer diagnósticos automatizados, mas sim explorar estruturas latentes nos dados laboratoriais capazes de refletir diferentes estados fisiopatológicos. Adicionalmente, a caracterização desses padrões pode fornecer subsídios para futuras estratégias

de estratificação de risco, apoio à decisão clínica e investigação epidemiológica baseada em dados reais de atendimento⁴.

Diante desse contexto, o presente estudo propõe a aplicação de técnicas de aprendizado de máquina não supervisionado para investigar padrões laboratoriais em pacientes atendidos em serviços de urgência e emergência. Utilizando parâmetros laboratoriais rotineiramente coletados nas primeiras 24 horas de atendimento e dados demográficos, buscou-se explorar a heterogeneidade biológica presente nessa população, identificando fenótipos laboratoriais latentes clinicamente interpretáveis. Adicionalmente, o estudo busca caracterizar os perfis laboratoriais e demográficos dos pacientes que procuram atendimento emergencial, explorando como diferentes estados fisiopatológicos podem emergir a partir da integração multimarcador de exames laboratoriais.

Métodos

Desenho do estudo e fonte de dados

Foi conduzido um estudo retrospectivo observacional utilizando dados laboratoriais provenientes de um sistema de informação laboratorial institucional. A base de dados incluiu registros de exames realizados entre janeiro de 2022 e dezembro de 2024 em serviços de urgência e emergência adulto e pediátrico. Todos os dados utilizados foram previamente anonimizados, sem identificação direta dos pacientes.

Cada atendimento clínico foi tratado como uma unidade independente de análise. Para reduzir a influência de coletas seriadas e garantir comparabilidade temporal entre os casos, foram considerados exclusivamente exames realizados nas primeiras 24 horas a partir do início do atendimento.

Seleção da coorte

A análise foi direcionada especificamente para pacientes atendidos em serviços de urgência e emergência, incluindo atendimentos adultos e pediátricos. Essa abordagem teve como objetivo explorar os perfis laboratoriais observados em uma população clínica heterogênea, representativa de cenários reais de atendimento emergencial.

Foram incluídos atendimentos contendo exames laboratoriais representativos de diferentes eixos fisiopatológicos relevantes na prática de emergência, incluindo parâmetros hematológicos, inflamatórios, renais e hepáticos. Os atendimentos sem variáveis laboratoriais mínimas necessárias para composição do vetor multivariado foram excluídos da análise.

Considerando a natureza dinâmica dos pacientes em ambiente de emergência, múltiplas coletas laboratoriais podiam estar disponíveis para um mesmo atendimento durante o período inicial de observação. Nesses casos, foi selecionado o valor de maior magnitude (*“peak value”*) para cada variável laboratorial dentro da janela temporal de 24 horas após o início do atendimento. Essa estratégia foi adotada com o objetivo de capturar alterações laboratoriais potencialmente mais representativas do estado fisiopatológico agudo do paciente durante a fase inicial do atendimento emergencial.

Variáveis laboratoriais e demográficas

As variáveis incluídas na análise foram:

- Hematológicas: leucócitos totais (LEUCO) e plaquetas (PLAQ);
- Inflamatórias: proteína C reativa (PCR);
- Renais: creatinina e ureia;
- Hepáticas: transaminase oxalacética (TGO/AST) e transaminase pirúvica (TGP/ALT);
- Demográficas: idade e sexo.

Os exames laboratoriais foram previamente padronizados quanto à nomenclatura, unidades de medida e representação numérica. Variáveis hematológicas com diferenças de escala entre registros foram harmonizadas para uma unidade comum, reduzindo inconsistências provenientes do processo de consolidação dos dados laboratoriais.

Pré-processamento dos dados

Os valores laboratoriais foram convertidos para formato numérico, e observações inválidas ou inconsistentes foram tratadas como ausentes. A distribuição das variáveis contínuas foi avaliada por estatística descritiva e análise

de assimetria, evidenciando presença de distribuições não gaussianas e valores extremos, particularmente para creatinina, proteína C reativa e transaminases.

Para redução da influência de assimetria e outliers, foi aplicada transformação logarítmica natural com deslocamento $[\log_{1p}(x)]$. Em seguida, as variáveis foram submetidas à padronização robusta utilizando o método RobustScaler, baseado em mediana e intervalo interquartil (IQR).

Os dados faltantes foram tratados por imputação utilizando o algoritmo *K-nearest neighbors* (KNN), considerando a estrutura multivariada dos dados e preservando relações entre variáveis laboratoriais.

Análise exploratória da coorte

As características demográficas e laboratoriais da população foram descritas utilizando mediana e intervalo interquartil (IQR) para variáveis contínuas e frequência absoluta e relativa para variáveis categóricas. A distribuição das variáveis foi avaliada globalmente e estratificada por sexo.

As comparações entre sexos foram realizadas utilizando o teste de Mann–Whitney para variáveis contínuas e o teste do qui-quadrado de *Pearson* para variáveis categóricas. Considerando o grande tamanho amostral, os resultados foram interpretados com ênfase na magnitude e plausibilidade clínica das diferenças observadas, e não exclusivamente na significância estatística.

Análise de agrupamento (*clustering*)

A identificação de fenótipos laboratoriais foi realizada por meio do algoritmo *K-means*. O número ótimo de clusters foi determinado utilizando a métrica de silhueta, avaliando soluções entre dois e seis agrupamentos. A solução final foi selecionada considerando simultaneamente interpretabilidade clínica e qualidade de separação dos grupos.

O modelo final foi ajustado utilizando inicialização controlada por *random seed* (*random_state* = 42), garantindo reprodutibilidade dos resultados.

Visualização em baixa dimensionalidade

Para representação visual da estrutura dos dados em baixa dimensionalidade, foi utilizada a técnica *Uniform Manifold Approximation and Projection* (UMAP). Essa abordagem permite preservar relações locais de

similaridade entre amostras em um espaço bidimensional, facilitando a visualização da distribuição dos fenótipos laboratoriais identificados.

Os eixos do UMAP não possuem interpretação clínica direta, sendo utilizados exclusivamente para exploração visual da organização latente dos dados.

adicionar github?

Caracterização dos fenótipos laboratoriais

Os clusters identificados foram caracterizados por meio de estatísticas descritivas robustas, incluindo mediana e intervalo interquartil para cada variável laboratorial e demográfica. A interpretação clínica dos fenótipos foi realizada posteriormente à clusterização, com base nos padrões predominantes observados em cada agrupamento.

Considerações éticas

O estudo utilizou exclusivamente dados secundários anonimizados, sem acesso a informações diretamente identificáveis dos pacientes, sendo conduzido em conformidade com os princípios éticos aplicáveis à pesquisa envolvendo dados clínicos.

COLOCAR NUMERO DE PARECER

Resultados

Descrição da amostra

Foram incluídos 26.414 atendimentos clínicos na análise final, após aplicação dos critérios de elegibilidade, consolidação temporal dos exames laboratoriais e etapas de pré-processamento dos dados. As variáveis laboratoriais apresentaram diferentes níveis de completude, com maior disponibilidade para parâmetros hematológicos, particularmente leucócitos e plaquetas, e menor disponibilidade para alguns marcadores bioquímicos específicos.

A análise exploratória das variáveis contínuas evidenciou distribuições não gaussianas e presença de assimetria acentuada, especialmente para creatinina,

proteína C reativa e transaminases hepáticas. Adicionalmente, observou-se presença de valores extremos em diferentes marcadores laboratoriais, refletindo a heterogeneidade clínica da população atendida. Esses achados justificaram a utilização de transformação logarítmica e padronização robusta previamente à análise de agrupamento.

Características	Total	Feminino	Masculino
Atendimentos, n	26414	14966	11448
Idade, mediana (IQR)	49.50 (30.5 - 67.9)	48.9 (30.30 - 68.20)	50.30 (31.00 - 67.60)
Distribuição por faixa etária			
<18 anos, n(%)	1837 (8.0%)	950 (7.3%)	887 (8.9%)
18-39 anos, n(%)	6786 (29.5%)	4009 (30.8%)	2777 (27.8%)
40-59 anos, n(%)	5966 (25.9%)	3359 (25.8%)	2607 (26.1%)
≥60 anos, n(%)	8430 (36.6%)	4713 (36.2%)	3717 (37.2%)

INSERIR TABELA HERE

A coorte apresentou elevada heterogeneidade demográfica e laboratorial, compatível com o perfil assistencial típico de serviços de urgência e emergência. Observou-se predominância de pacientes idosos, ampla variabilidade nos marcadores inflamatórios e diferenças substanciais nos parâmetros relacionados à função renal e hepática.

Identificação dos fenótipos laboratoriais

A análise de clustering por *K-means* indicou a presença de três agrupamentos como solução mais adequada, considerando o equilíbrio entre interpretabilidade clínica e qualidade de separação (silhouette = 0,29).

A distribuição dos atendimentos entre os clusters foi:

- **Cluster 2 (fenótipo basal):** 70,8%
- **Cluster 0 (fenótipo inflamatório-renal):** 22,7%
- **Cluster 1 (fenótipo hepático):** 6,4%

Caracterização dos clusters

Os clusters apresentaram perfis laboratoriais distintos (Tabela X).

Cluster 0 – Fenótipo inflamatório-renal

Caracterizado por elevação de marcadores inflamatórios e de função renal:

- PCR: 28,87 mg/L (IQR 10,61–84,72)
- Creatinina: 1,44 mg/dL (1,02–2,20)
- Ureia: 63,24 mg/dL (44,06–102,82)
- Idade: 70,8 anos (53,5–81,3)

Esse grupo apresentou também níveis moderadamente elevados de leucócitos, sugerindo resposta inflamatória sistêmica associada a disfunção orgânica.

Cluster 1 – Fenótipo hepático

Caracterizado por elevação de enzimas hepáticas e alterações hematológicas:

- TGO: 62,2 U/L (46,2–102,4)
- TGP: 52,6 U/L (34,1–91,3)
- Leucócitos: 4.515 (3.012–6.840)
- Plaquetas: 136.000 (98.000–189.000)

Esse padrão sugere um perfil compatível com injúria hepática associada a discreta citopenia relativa.

Cluster 2 – Fenótipo basal

Representou a maior parte da amostra, com valores laboratoriais próximos da normalidade:

- PCR: 7,81 mg/L (2,01–23,04)
- Creatinina: 0,78 mg/dL (0,63–0,96)
- TGO: 21,0 U/L (15,0–29,0)
- TGP: 17,2 U/L (12,0–25,0)
- Idade: 49,1 anos (29,7–68,4)

Esse grupo pode ser interpretado como um fenótipo de menor gravidade clínica ou ausência de disfunção orgânica significativa.

Visualização dos fenótipos

A projeção bidimensional por UMAP (Figura 1) demonstrou que os clusters ocupam regiões parcialmente separáveis no espaço latente, com sobreposição entre grupos. O fenótipo basal apresentou maior densidade e distribuição central, enquanto os fenótipos inflamatório-renal e hepático se distribuíram em regiões mais periféricas e distintas.

Essa configuração sugere a presença de estrutura latente nos dados laboratoriais, ao mesmo tempo em que reflete a natureza contínua da variação clínica.

Associação com contexto assistencial

A distribuição dos clusters variou entre os contextos assistenciais avaliados, com predominância de todos os fenótipos em ambientes de maior complexidade.

A análise de associação por teste do qui-quadrado demonstrou significância estatística:

- $\chi^2 = 108,3$
- $p < 0,001$

No entanto, o tamanho de efeito foi pequeno:

- **V de Cramér = 0,052**

Indicando que, apesar da associação estatística, a magnitude da relação entre fenótipos laboratoriais e contexto assistencial é limitada.

Distribuição demográfica

A distribuição por sexo mostrou leve predominância do sexo feminino em todos os clusters:

- Cluster 0: 51,3% feminino
- Cluster 1: 54,6% feminino
- Cluster 2: 58,5% feminino

A idade foi semelhante entre os clusters 1 e 2, mas significativamente maior no cluster inflamatório-renal, reforçando a associação desse fenótipo com pacientes mais idosos.

Síntese dos achados

A análise revelou três fenótipos laboratoriais distintos, com padrões biologicamente plausíveis e clinicamente interpretáveis. A fraca associação com o contexto assistencial sugere que esses padrões refletem variação biológica intrínseca, mais do que diferenças relacionadas ao ambiente de atendimento.

Discussão

Este estudo demonstrou que dados laboratoriais multimarcadores, obtidos nas primeiras 24 horas de atendimento, são capazes de revelar fenótipos clínicos distintos por meio de aprendizado de máquina não supervisionado, independentemente do contexto assistencial. Três padrões principais foram identificados — inflamatório-renal, hepático e basal — todos com coerência fisiopatológica e distribuição consistente na projeção em baixa dimensionalidade.

Um dos achados centrais foi a fraca associação entre os fenótipos e o contexto assistencial (V de Cramér = 0,052), apesar da significância estatística. Esse resultado é relevante, pois desafia a suposição implícita de que o ambiente de atendimento (por exemplo, urgência/emergência versus ambulatorial) seja um determinante primário da gravidade ou do perfil biológico do paciente. Em vez disso, nossos dados sugerem que existe heterogeneidade substancial dentro de cada contexto clínico, com pacientes organizando-se em padrões laboratoriais próprios, possivelmente refletindo estados fisiopatológicos distintos.

Esse achado está alinhado com o conceito de fenotipagem baseada em dados, amplamente discutido na literatura recente, especialmente em doenças complexas como sepse e síndrome do desconforto respiratório agudo. Estudos como o de Christopher W. Seymour et al. demonstraram que abordagens não supervisionadas podem identificar subfenótipos clínicos com relevância prognóstica

e terapêutica, frequentemente não capturados por classificações tradicionais baseadas em diagnóstico clínico (Seymour et al., 2019). De forma semelhante, Carolyn S. Calfee et al. evidenciaram que fenótipos inflamatórios distintos em pacientes críticos podem apresentar respostas diferentes a intervenções, reforçando a importância de abordagens orientadas por dados (Calfee et al., 2014).

No presente estudo, embora não tenham sido avaliados desfechos clínicos, a identificação de um fenótipo inflamatório-renal associado a maior idade sugere possível correlação com maior gravidade clínica, uma vez que inflamação sistêmica e disfunção renal são marcadores bem estabelecidos de pior prognóstico em diversas condições (Hoste et al., 2018). Da mesma forma, o fenótipo hepático, caracterizado por elevação de transaminases e alterações hematológicas, pode refletir processos inflamatórios, infecciosos ou tóxico-metabólicos, frequentemente observados em cenários clínicos complexos (Giannini et al., 2005).

A visualização por UMAP demonstrou que os fenótipos ocupam regiões parcialmente separáveis, porém sobrepostas, no espaço latente. Esse padrão é consistente com a natureza contínua da variação biológica, na qual não existem fronteiras rígidas entre estados fisiopatológicos. Esse comportamento já foi descrito em estudos de aprendizado de representação em dados biomédicos, nos quais embeddings de alta dimensionalidade preservam estruturas locais, mas revelam transições graduais entre grupos (McInnes et al., 2018).

Importante destacar que o valor de silhueta obtido ($\approx 0,29$), embora moderado, é esperado em dados clínicos reais, caracterizados por alta variabilidade e ruído. Diferentemente de datasets sintéticos ou altamente controlados, a ausência de separação perfeita não representa limitação, mas sim realismo, reforçando a validade externa dos achados. Nesse contexto, a interpretabilidade clínica dos clusters torna-se mais relevante do que métricas puramente geométricas.

Outro aspecto metodológico relevante foi a padronização das unidades laboratoriais, particularmente para variáveis hematológicas. A presença de diferentes escalas (por exemplo, contagens absolutas versus milhares por microlitro) pode introduzir artefatos significativos em análises baseadas em distância. A correção dessas inconsistências foi essencial para garantir que os agrupamentos refletissem padrões biológicos reais, e não diferenças técnicas — um problema frequentemente subestimado em estudos com dados laboratoriais de mundo real.

Do ponto de vista clínico, os resultados sugerem que a análise integrada de múltiplos biomarcadores pode oferecer uma visão mais abrangente do estado do paciente, em comparação com abordagens tradicionais baseadas em exames isolados. Essa perspectiva está em linha com a crescente adoção de estratégias de medicina de precisão, nas quais a estratificação de pacientes baseada em dados multidimensionais tem potencial para melhorar a tomada de decisão clínica (Johnson et al., 2016).

Conclusão

Este estudo demonstrou que dados laboratoriais multimarcaadores, obtidos nas primeiras 24 horas de atendimento, permitem a identificação de fenótipos clínicos distintos por meio de aprendizado de máquina não supervisionado. Três padrões principais — inflamatório-renal, hepático e basal — foram consistentemente identificados, apresentando coerência fisiopatológica e distribuição estruturada no espaço latente.

Apesar de diferenças estatisticamente significativas na distribuição dos fenótipos entre contextos assistenciais, o baixo tamanho de efeito observado indica que esses padrões são apenas fracamente influenciados pelo ambiente de atendimento. Esse achado sugere que a variabilidade biológica dos pacientes exerce papel mais relevante na organização dos dados laboratoriais do que o próprio contexto clínico.

Os resultados reforçam o potencial da fenotipagem baseada em dados como abordagem complementar para estratificação de pacientes, permitindo uma visão mais integrada e objetiva do estado fisiopatológico. Em conjunto, essas evidências apontam para aplicações futuras em suporte à decisão clínica, medicina de precisão e análise de grandes bases de dados em saúde.

Estudos futuros devem incorporar desfechos clínicos, validação externa e análise longitudinal, a fim de aprofundar a compreensão da relevância prognóstica e aplicabilidade desses fenótipos na prática clínica.

Referências

1. MUTLU, Senan; ÇETINKAYA, Aynur ; YILMAZ, Emel. Emergency Service Perceptions

and Experiences of Patients: “Not A Great Place, But Not Disturbing”. **Journal of Patient Experience**, v. 8, p. 237437352110342, 2021.

2. BEŞTEMİR, Attila ; BOZDERELİ BERİKOL, Göksu. Clinical laboratory testing in the emergency department: a six-year analysis. **Turkish Journal of Biochemistry**, v. 48, n. 5, p. 467–474, 2023.

3. NEMATI, Sepehr; MOHAMMADI, Babak ; HOOSHANGINEZHAD, Zahra. Clustering Based on Laboratory Data in Patients With Heart Failure Admitted to the Intensive Care Unit. **Journal of Clinical Laboratory Analysis**, v. 38, n. 21, 2024.

4. BECKER, Florian; SMILDE, Age K ; ACAR, Evrim. Unsupervised EHR-based phenotyping via matrix and tensor decompositions. **WIREs Data Mining and Knowledge Discovery**, v. 13, n. 4, 2023.